

LGN 5822 - Statistical Genetics I: Foundations

Normalidade em modelos estatísticos: do diagnóstico à tomada de decisão

Discentes: Ana Matussi, Paula Cardoso e Thiago Ludwig

Docente: Prof. Dr. Saulo Chaves

Afinal, o que precisa ser normal?

Em modelos lineares, a suposição de normalidade está relacionada aos erros do modelo, e não necessariamente aos dados brutos.

$$\underbrace{y_i}_{\text{Observado}} = \underbrace{\hat{y}_i}_{\text{Valor ajustado}} + \underbrace{e_i}_{\text{Resíduo}}$$

O ponto principal é avaliar se a parte não explicada pelo modelo (resíduos), se comporta de forma aproximadamente normal.

Conceito




Erro

Variabilidade intrínseca e desconhecida da população

Resíduo

Diferença calculada entre o valor observado e o valor ajustado pelo modelo




A Natureza do Erro: $\varepsilon \sim N(0, \sigma^2)$

Erro em um modelo ideal:

Erros experimentais são aleatórios, não enviesados (média 0) e seguem uma distribuição normal com variância constante.

Por que a suposição de normalidade é necessária?

- **Teste t**
- **ANOVA**
- **Regressão Linear**



Testes paramétricos

Eles foram desenvolvidos sob o pressuposto matemático de que os erros do modelo seguem uma distribuição normal, por isso a necessidade de suposição da normalidade



Importância

Caso não haja o cumprimento da suposição pode ocorrer falta de confiabilidade das análises



Comprometimento do p-valor

Sem normalidade nos resíduos, o p-valor torna-se uma estimativa falsa, comprometendo a conclusão estatística



Levar a conclusões erradas

Erro Tipo I: o risco de declarar um efeito inexistente como significativo aumenta drasticamente.



Impacto do tamanho amostral

A rigidez desse pressuposto varia conforme o tamanho da sua amostra:

Amostras Grandes





Teorema Central do Limite

Para amostras muito grandes a média tende a ser normal.

Amostras Pequenas

A normalidade dos resíduos é crítica, qualquer desvio da normalidade invalida o teste.

Como verificar a normalidade?



Testes de normalidade

Teste	Melhor Para	Sensibilidade
Shapiro-Wilk	Amostras Pequenas/Médias ($n < 50$)	Geral, muito potente
Kolmogorov-Smirnov	Amostras Grandes ($n > 50$)	Baixa, central
Anderson-Darling	Amostras Médias/Grandes, maior peso às caudas (extremos) da distribuição.	Alta nas caudas

E se a normalidade não for atendida?

Quando os resíduos não seguem bem uma distribuição normal, é possível adotar algumas estratégias.

1. Investigar os dados e o modelo

Antes de transformar ou trocar o método, é preciso entender por que os resíduos não estão normais.

- Identificar Outliers
- Verificar assimetria
- Considerar o tamanho da amostra
- Avaliar valores extremos/influentes
- Investigar dependência entre observações
- Verificar se o modelo está bem especificado



E se a normalidade não for atendida?

Quando os resíduos não seguem bem uma distribuição normal, é possível adotar algumas estratégias.

2. Transformação da variável resposta

- Transformação logarítmica ($\log(y)$)
- Raiz quadrada ($\sqrt{y}$)
- Box-Cox

Objetivo: reduzir a assimetria, estabilizar a variância e aproximar os resíduos da normalidade, melhorando a inferência, como testes t, testes F e ANOVA.

3. Usar modelos ou métodos alternativos

- Modelos Lineares Generalizados (GLM)
- Método Bootstrap
- Métodos não paramétricos
 - Mann-Whitney
 - Kruskal-Wallis
 - Correlação de Spearman

Conclusão

- A **normalidade deve ser avaliada nos resíduos**, não apenas nos dados brutos;
- A **normalidade é importante para a inferência estatística**, como testes, p-valores e intervalos de confiança;
- O **QQ-plot** é uma das ferramentas mais informativas para avaliar a normalidade dos resíduos;
- **Quando a normalidade não é atendida**, é preciso investigar a causa antes de transformar os dados ou trocar o método.

O objetivo não é provar normalidade perfeita, mas avaliar se os desvios comprometem a análise.

Exemplo prático no R



Diagnóstico da normalidade dos resíduos em dois cenários:

- **mtcars**: modelo com resíduos aproximadamente normais;
- **airquality**: modelo com violação da normalidade;
 - Transformação logarítmica da resposta;
- Comparação visual **antes** vs **depois**.

Material complementar disponível no GitHub: https://github.com/Amatiussi/Statistical_Genetics.git

- Relatório em Quarto + script em R